BIOSTATISTIKA

L04

O kolik déle čekáme po delší erupci — a jak jistě to víme?



Od odhadu k nejistotě

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

Gejzír Old Faithful v číslech



LÉTO 2024

- 117 zaznamenaných erupcí
- erupce trvá přibližně **1,5–5 minut**
- čekání na další erupci: obvykle **50–127 minut**
- pozorování dobrovolníků ze služby GeyserTimes

Napoví délka právě skončené erupce, jak dlouho budeme čekat na další?

Foto: NPS/Jim Peaco, public domain. Rozsahy: National Park Service.

Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

Dva kosatce se liší šířkou korunního lístku o 0,5 cm. O kolik se podle modelu v průměru liší jejich odhadnutá délka lístku?

```
> coef(mod_listky)
 (Intercept) sirka_listku
        1.08         2.23
```

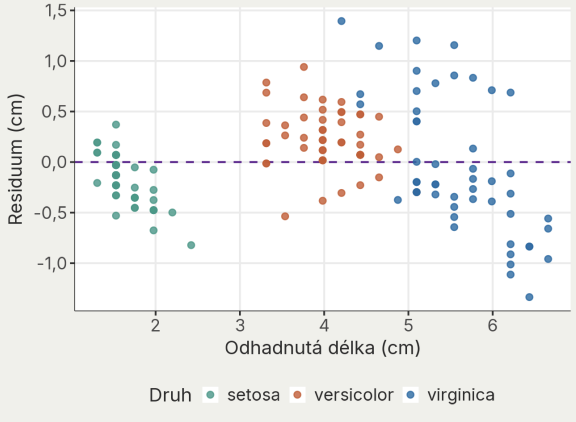
- Asi o 2,2 cm
- Asi o 4,5 cm
- Asi o 1,1 cm
- Nelze určit bez šířek obou květů

SPRÁVNÁ ODPOVĚĎ

: Asi o 1,1 cm

Sklon 2,23 cm/cm vynásobíme rozdílem šířek: 2,23 · 0,5 ≈ 1,1 cm. Intercept se při porovnání dvou květů odečte, takže jejich konkrétní šířky nepotřebujeme.

Residua kosatců druhu versicolor leží převážně nad nulou. Co z toho plyne?



Model jejich délku převážně podhodnocuje; v modelu chybí informace o druhu.

Model jejich délku převážně nadhodnocuje; v modelu chybí informace o druhu.

Nic; residua všech květů mají dohromady průměr nula, model je v pořádku.

Versicolor má ze všech druhů nejdelší lístky, proto má kladná residua.

SPRÁVNÁ ODPOVĚĎ

: Model jejich délku převážně podhodnocuje; v modelu chybí informace o druhu.

Kladné residuum: naměřená délka je větší než odhad, model ji podhodnocuje. Průměr nula platí pro všechna residua dohromady, ne pro každý druh; posun skupiny ukazuje chybějící prediktor.

Dvě přímky mají pro stejné čtyři květy tato residua. Která přímka popisuje květy lépe?

Residua (cm)	květ 1	květ 2	květ 3	květ 4
První přímka	+0,5	-0,5	+0,5	-0,5
Druhá přímka	+0,2	-0,1	+0,2	-0,1

- První přímka, protože součet jejích residuí je nula.
- Obě stejně, protože obě mají kladná i záporná residua.
- Nelze rozhodnout, dokud neznáme intercept a sklon obou přímek.
- Druhá přímka, protože součet čtverců jejích residuí je menší.

SPRÁVNÁ ODPOVĚĎ

: Druhá přímka, protože součet čtverců jejích residuí je menší.
Kladná a záporná residua se v součtu ruší, proto je umocňujeme: první přímka má součet čtverců 1,00 cm², druhá jen 0,10 cm².

Výsledky učení

Po absolvování této přednášky budete schopni:

- vysvětlit, proč jiný soubor pozorování dává jiný odhad sklonu
- najít ve výstupu `summary()` odhad sklonu a jeho standardní chybu a rozlišit velikost vztahu od přesnosti odhadu
- získat 95% interval spolehlivosti sklonu funkcí `confint()` a pás spolehlivosti kolem přímky funkcí `predict()` a interpretovat je bez tvrzení, že obsahují 95 % pozorování nebo dokazují hypotézu
- zapsat výsledek jednou větou s odhadem, SE, intervalem a jednotkami

Dají jiné erupce stejnou přímku?

Každý řádek je jedna erupce

```r
# Načteme tabulku erupcí
data_gejzir <-
  read.csv(file = "data/old_faithful_2024.csv")

# Datum převedeme na kalendářní datum
data_gejzir$date <-
  as.Date(x = data_gejzir$date)

# Délku erupce převedeme ze sekund na minuty
data_gejzir$delka_erupce_min <-
  data_gejzir$duration / 60

# Počet erupcí
nrow(x = data_gejzir)
```

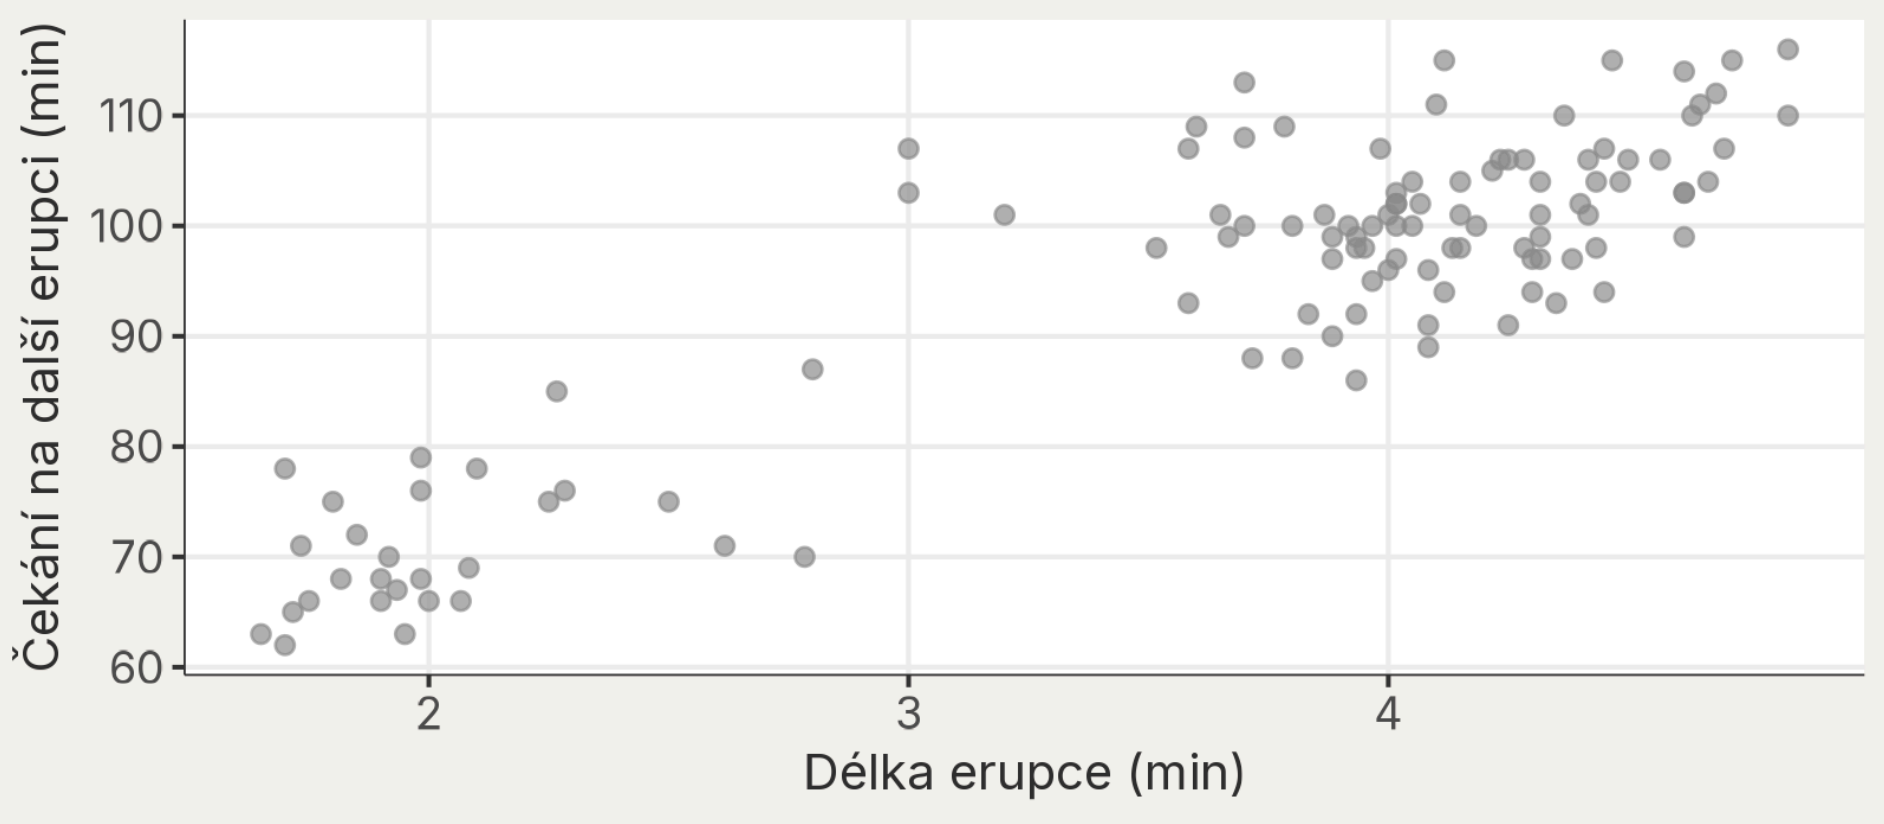
```
[1] 117
```

```r
# Celkový počet chybějících hodnot
sum(is.na(x = data_gejzir))
```

```
[1] 0
```

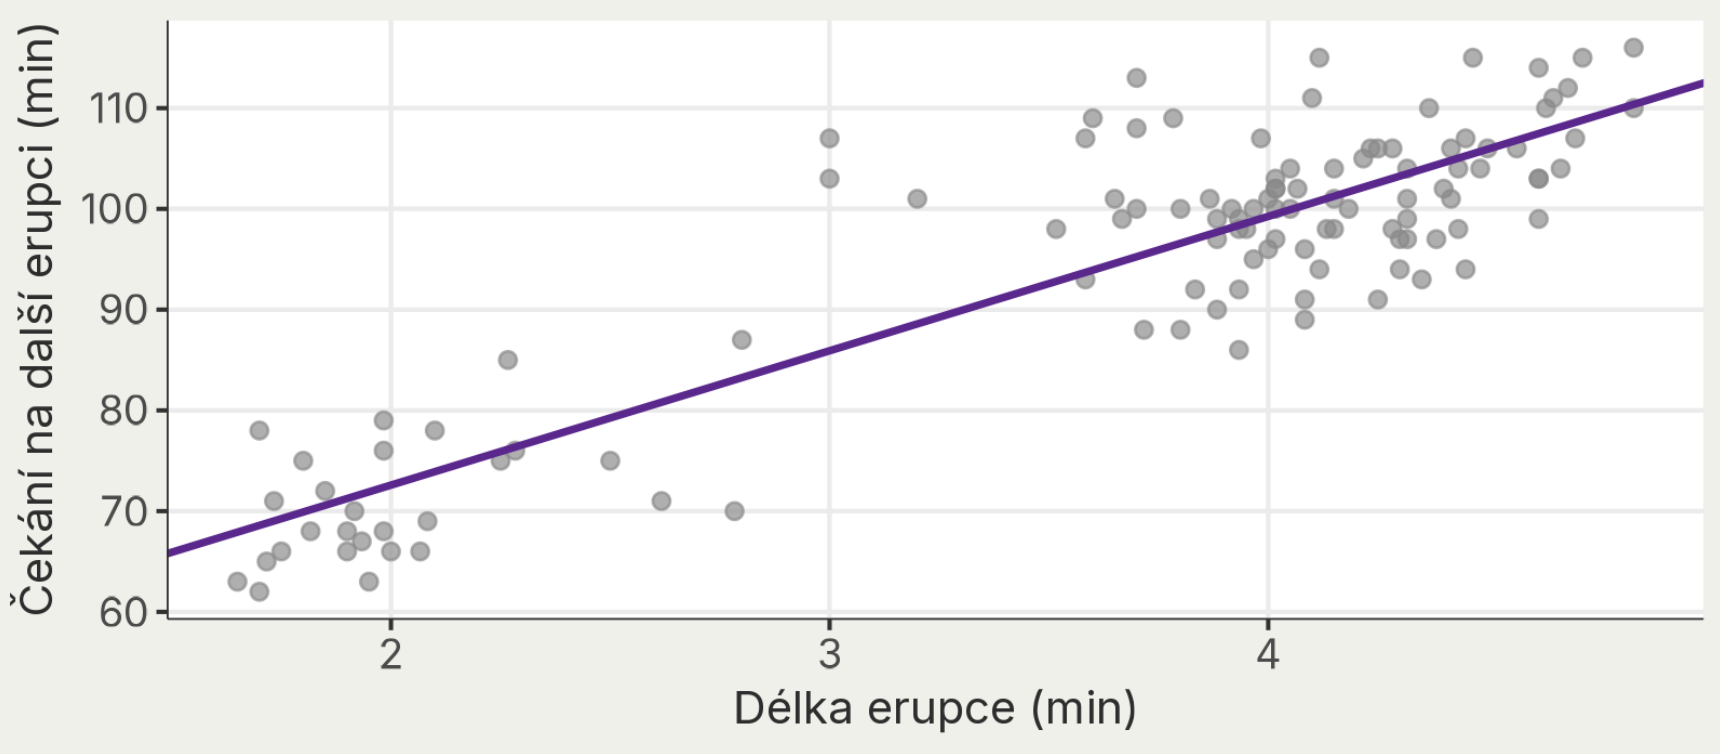
old_faithful_2024.csv: uložte do složky `data` ve svém projektu v R.

Delší erupce, delší čekání?



Jaký směr má vztah? Kde je nejvíc bodů? Leží body na jediné přímce?

Přímka z tohoto léta



Odhadnutý sklon: **13,34 minuty čekání na minutu erupce**

Stejná data + stejný vzorec modelu = vždy stejné odhady. Funkce `lm()` nic náhodně nelosuje.

Dostali bychom příště stejnou přímku?

OTÁZKA

Gejzír pozoruje **někdo jiný v jiných dnech**, zaznamená své **body** a fituje stejný model. Jaký **sklon** dostane?

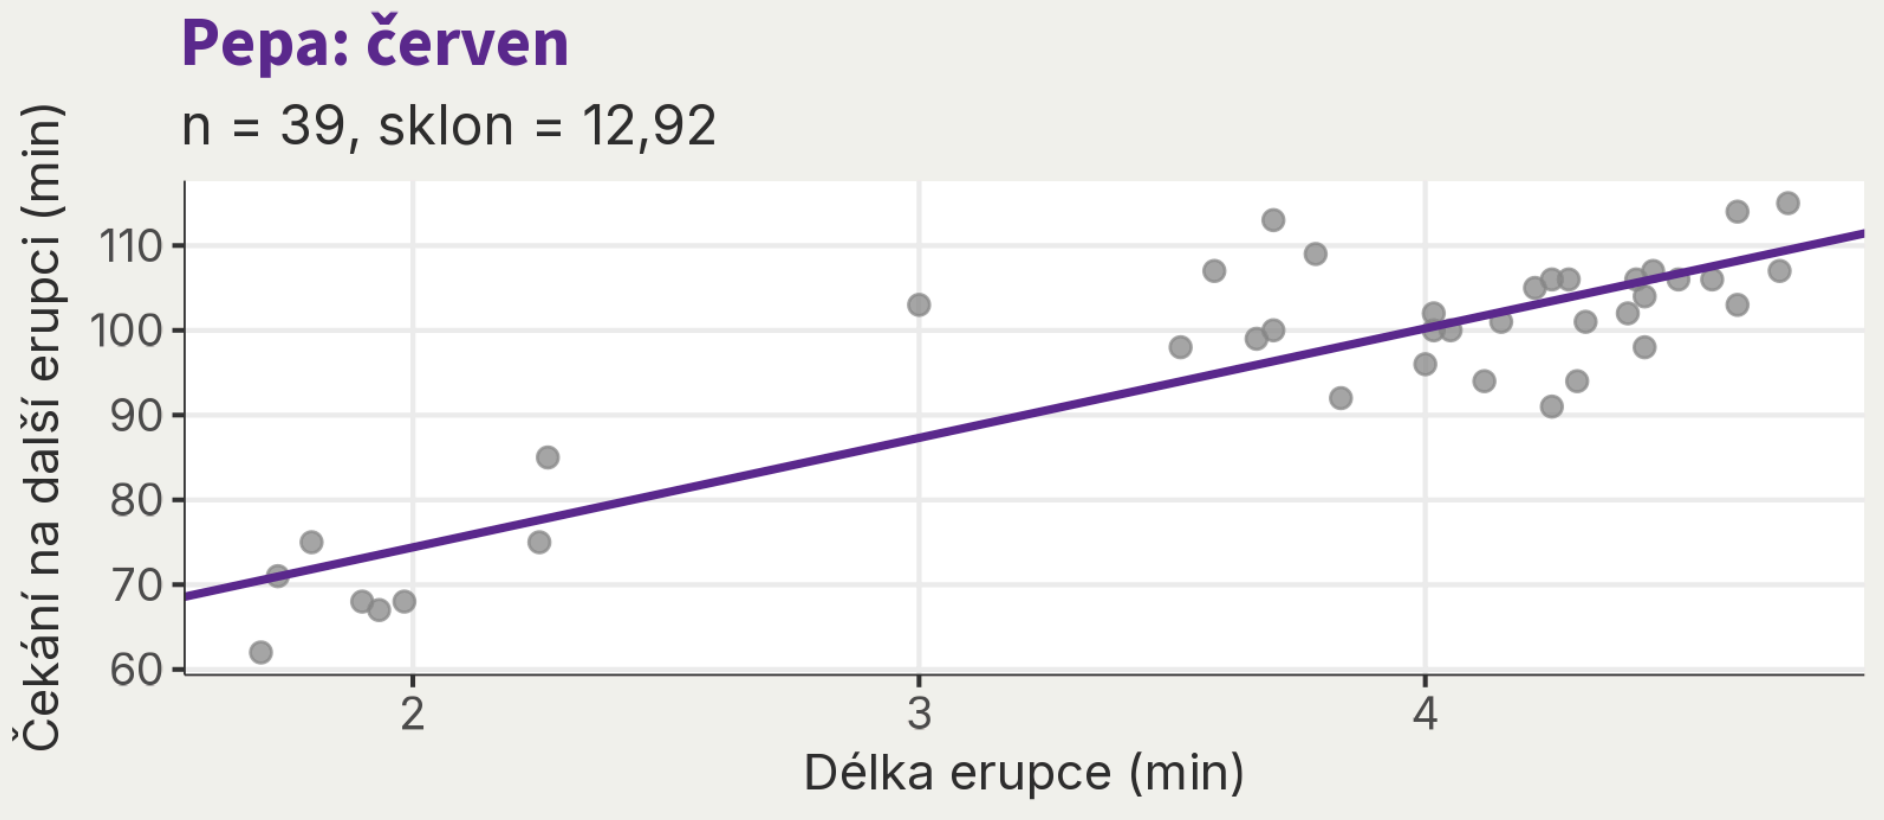
A) Přesně stejný sklon jako my.

B) Podobný, ale ne stejný sklon.

C) Úplně jiný sklon, nesouvisející s naším.

> Zvolte A, B, nebo C a zdůvodněte svou volbu sousedovi.

Pepa pozoroval pouze červen



V Pepových datech se dvě erupce, jejichž délky se liší o minutu, v průměru liší čekáním o **12,92 minuty**.

Co čekáte od Mařenky a Karla?

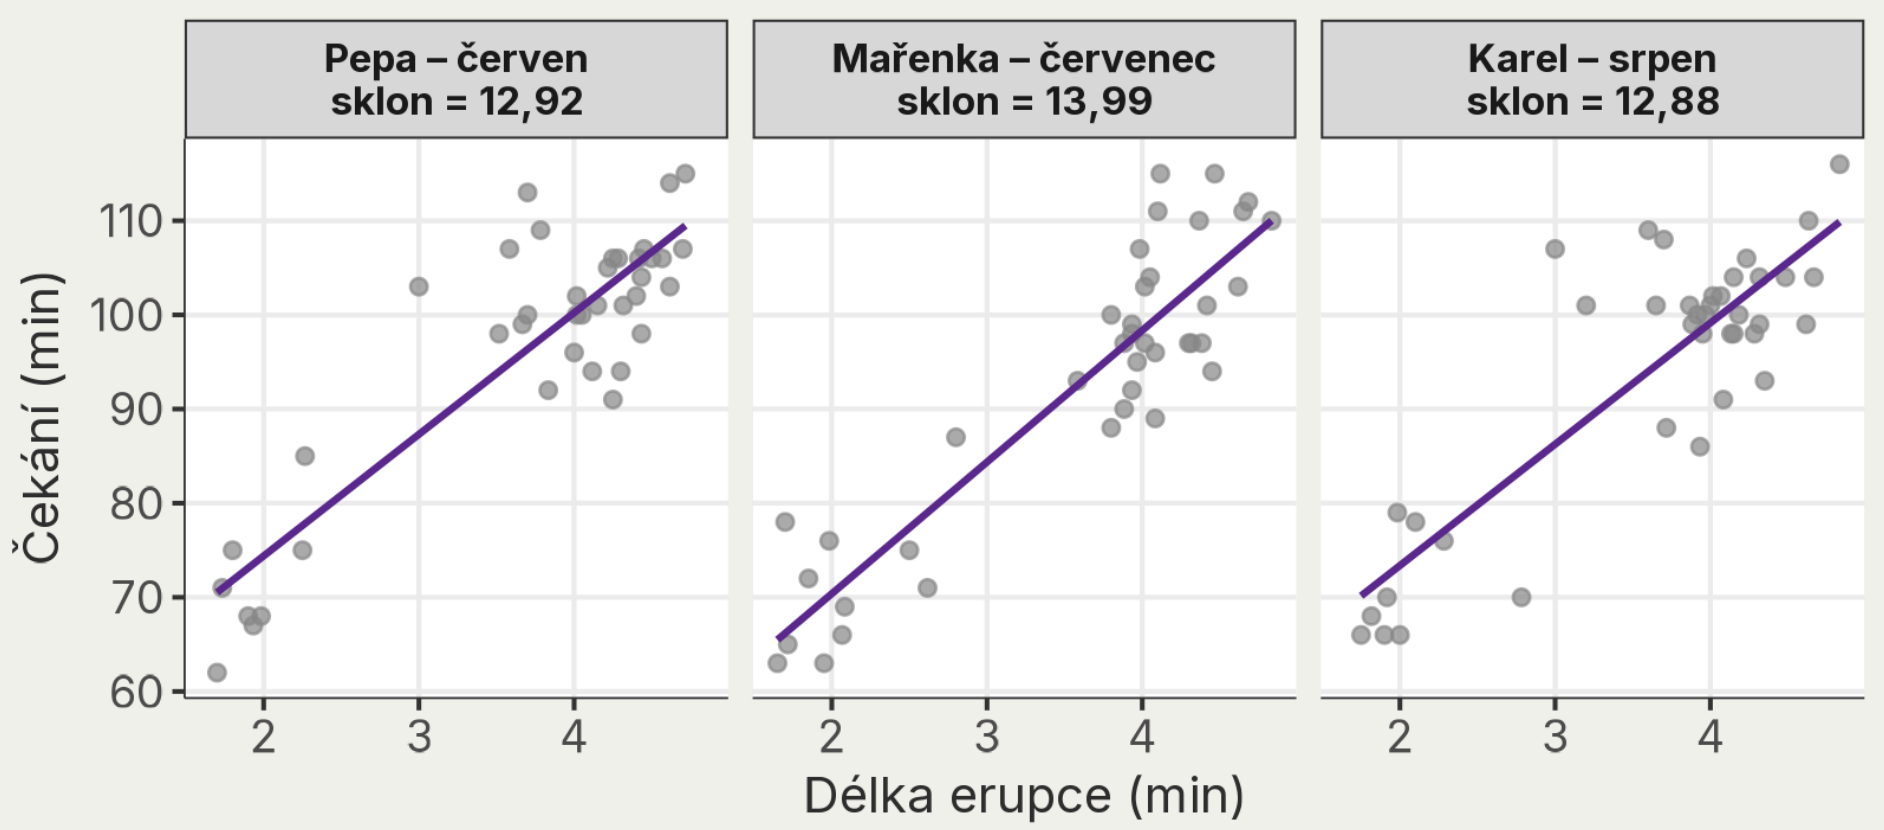
DISKUZE SE SOUSEDEM — 1 MIN

Mařenka pozoruje v červenci, Karel v srpnu. Oba použijí stejné proměnné a stejný model jako Pepa. **Budou všechny tři sklony stejné? Proč ano, nebo proč ne?**



Ilustrace vytvořená pomocí AI.

Stejný postup, tři různé výsledky



Rozdíly mezi měsíci mohou odrážet jiný výběr erupcí i skutečnou změnu chování gejzíru. Tři měsíce tyto příčiny neoddělí.

Odhad není oddělený od dat

CO ZŮSTALO STEJNÉ

- otázka a proměnné
- lineární model
- funkce `lm()`

CO SE ZMĚNILO

- pozorované erupce
- odhadnutá přímka a její sklon

Jednomu souboru pozorování říkáme **výběr** (*sample*). Proměnlivost odhadu mezi možnými výběry je výběrová variabilita (*sampling variability*).

Sto pozorovatelů, sto sklonů

Co udělá sto dalších pozorovatelů?

Každý pošle do aplikace GeyserWatch 40 erupcí, fituje stejný model a získá jeden sklon.

Jak budou vypadat všechny sklony společně?

> Ve dvojici nakreslete hrubý tvar, který očekáváte po 100 hlášeních.

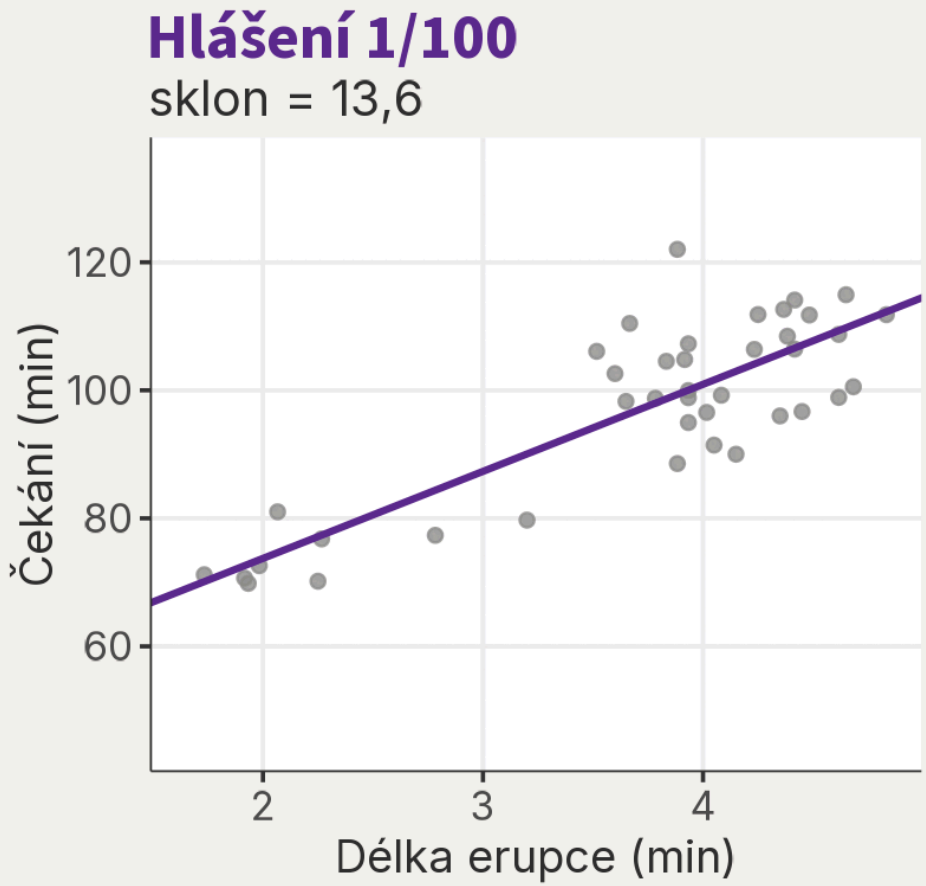


Ilustrace vytvořená pomocí AI.

SIMULACE

Délky erupcí z našich dat; čekání podle přímky z tohoto léta (sklon 13,34) s náhodnými odchylkami velkými jako residua. Tento **referenční sklon** známe jen v ukázce; skutečný sklon všech erupcí neznáme.

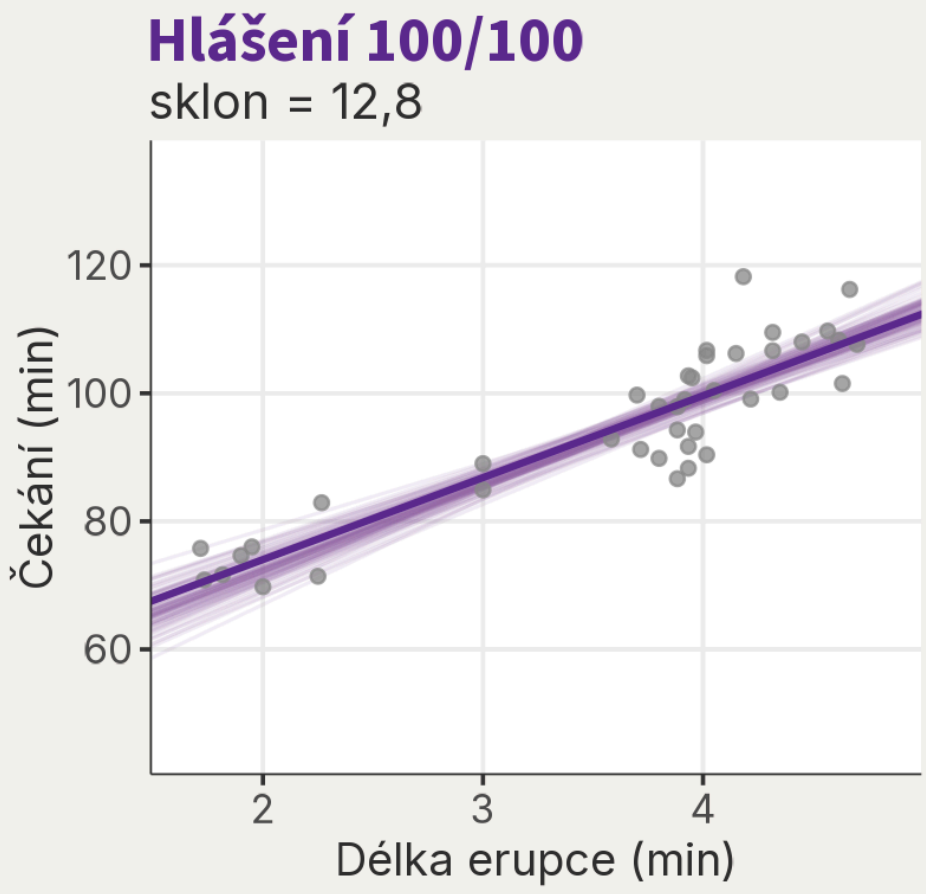
Sledujte cestu jednoho sklonu





Nový soubor bodů → nová přímka → nový sklon → další díl histogramu.

Po 100 hlášeních





Co vidíme — a co ještě nevíme?

CO VIDÍME

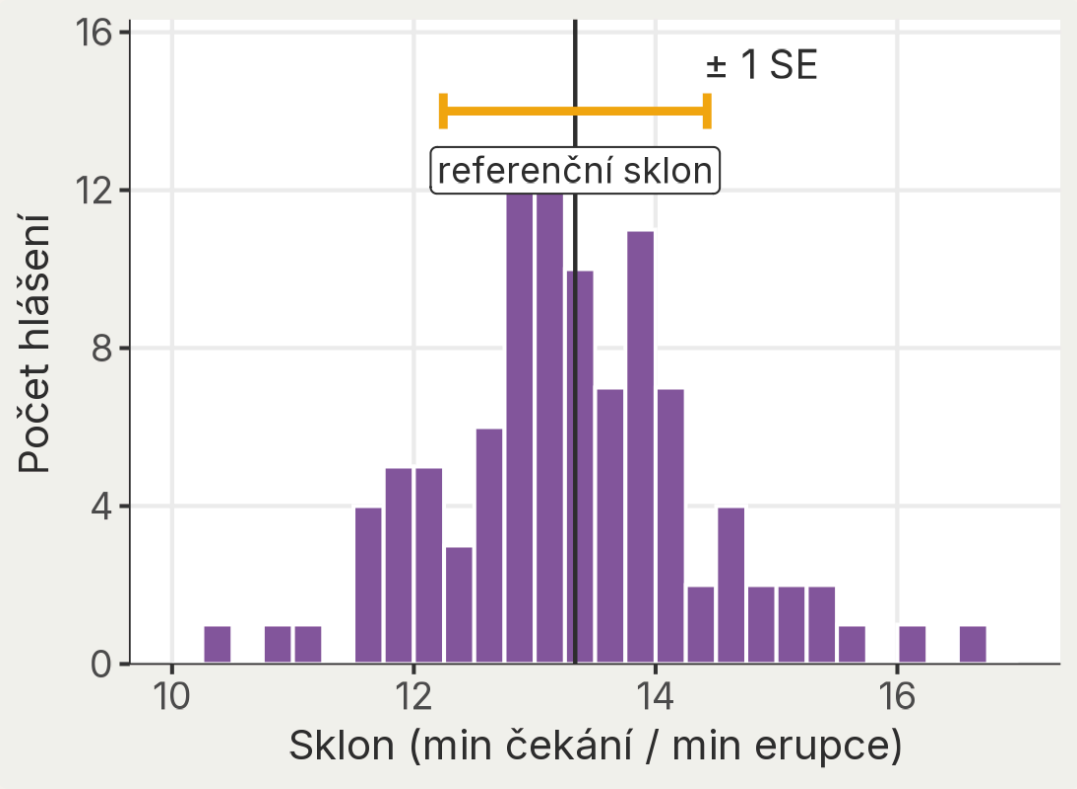
- sklony nejsou stejné
- většina leží ve společné oblasti
- některé výběry dávají strmější, jiné plošší přímku

CO JEŠTĚ NEVÍME

- jak šířku histogramu popsat jedním číslem
- jak ji odhadnout, když máme jen jeden výběr
- jaký rozsah sklonů je s daty slučitelný

Jedno číslo pro přesnost

Jak široce se sklony rozptylují?



ZE STA HLÁŠENÍ

Směrodatná odchylka 100 sklonů: **1,09**

Z JEDINÉHO HLÁŠENÍ

`summary()` u sklonu vypíše `Std. Error`, typicky **1,09**

Standardní chyba (SE) odhaduje z jediného výběru, jak moc by se sklony typicky lišily mezi výběry stejné velikosti.

Rozsah „± 1 SE“ kolem referenčního sklonu ještě není interval spolehlivosti.

Najděte velikost a přesnost

```r
# Model ze všech erupcí
mod_gejzir <-
  lm(
    formula = cekani_min ~ delka_erupce_min,
    data = data_gejzir
  )

summary(object = mod_gejzir)
```

```
Call:
lm(formula = cekani_min ~ delka_erupce_min, data = data_gejzir)

Residuals:
     Min       1Q   Median       3Q      Max
-13.0280  -4.4756  -0.3648   3.6354  21.0827

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)      45.9122     2.4658   18.62   <2e-16 ***
delka_erupce_min 13.3350     0.6575   20.28   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.833 on 115 degrees of freedom
Multiple R-squared:  0.7815,    Adjusted R-squared:  0.7796
F-statistic: 411.4 on 1 and 115 DF,  p-value: < 2.2e-16
```

DVOJICE — 1 MIN

Najděte číslo, které popisuje

1. **velikost vztahu**,
2. **přesnost tohoto odhadu**.

ŘÁDEK `delka_erupce_min`

- `Estimate` = 13,34 min/min
- `Std. Error` = 0,66 min/min

SE ze všech 117 erupcí je menší než z 40: více pozorování, přesnější odhad.

Velikost vztahu, nebo přesnost?

> Ve dvojici přiřaďte každou otázku k jednomu ze dvou čísel.

„O kolik minut se v průměru liší čekání po erupcích lišících se o minutu?“
Velikost vztahu (`Estimate`)

„Je vztah prudký, nebo pozvolný?“
Velikost vztahu (`Estimate`)

„Jak moc by se odhad lišil mezi výběry?“
Přesnost odhadu (`Std. Error`)

„Jak těsně se možné odhady shlukují?“
Přesnost odhadu (`Std. Error`)

Jaké sklony jsou s daty slučitelné?

Jak z odhadu a SE vytvořit rozsah?

Máme odhad 13,335 a SE 0,657 (na tři desetinná místa). Kolik standardních chyb přidat na každou stranu?

$$\text{polovina šířky} = \text{kritická hodnota} \times \text{SE} = 1{,}981 \times 0{,}657 = 1{,}302$$

$$\text{dolní hranice} = 13{,}335 - 1{,}302 = 12{,}033$$

$$\text{horní hranice} = 13{,}335 + 1{,}302 = 14{,}637$$

Pro 95% interval je **kritická hodnota** blízko 2; její přesnou hodnotu vysvětlíme v následující lekci.

Stejný interval v R

```r
# 95% intervaly spolehlivosti koeficientů
confint(object = mod_gejzir)
```

```
                   2.5 %   97.5 %
(Intercept)      41.02795 50.79642
delka_erupce_min 12.03274 14.63731
```

ŘÁDEK `delka_erupce_min`

12,03 až 14,64 minuty čekání na minutu erupce — stejné hranice jako ručně.

Sloupce `2.5 %` a `97.5 %`: 95% interval nechává na každé straně 2,5 %.

95% interval spolehlivosti



Pro Old Faithful: **[12,03; 14,64]** minuty čekání na minutu erupce.

> Interval popisuje nejistotu **sklonu**, ne rozmezí čekání po jedné budoucí erupci — jednotlivá čekání se navíc rozptylují kolem přímky.

Co se stane při vyšší hladině?

OTÁZKA

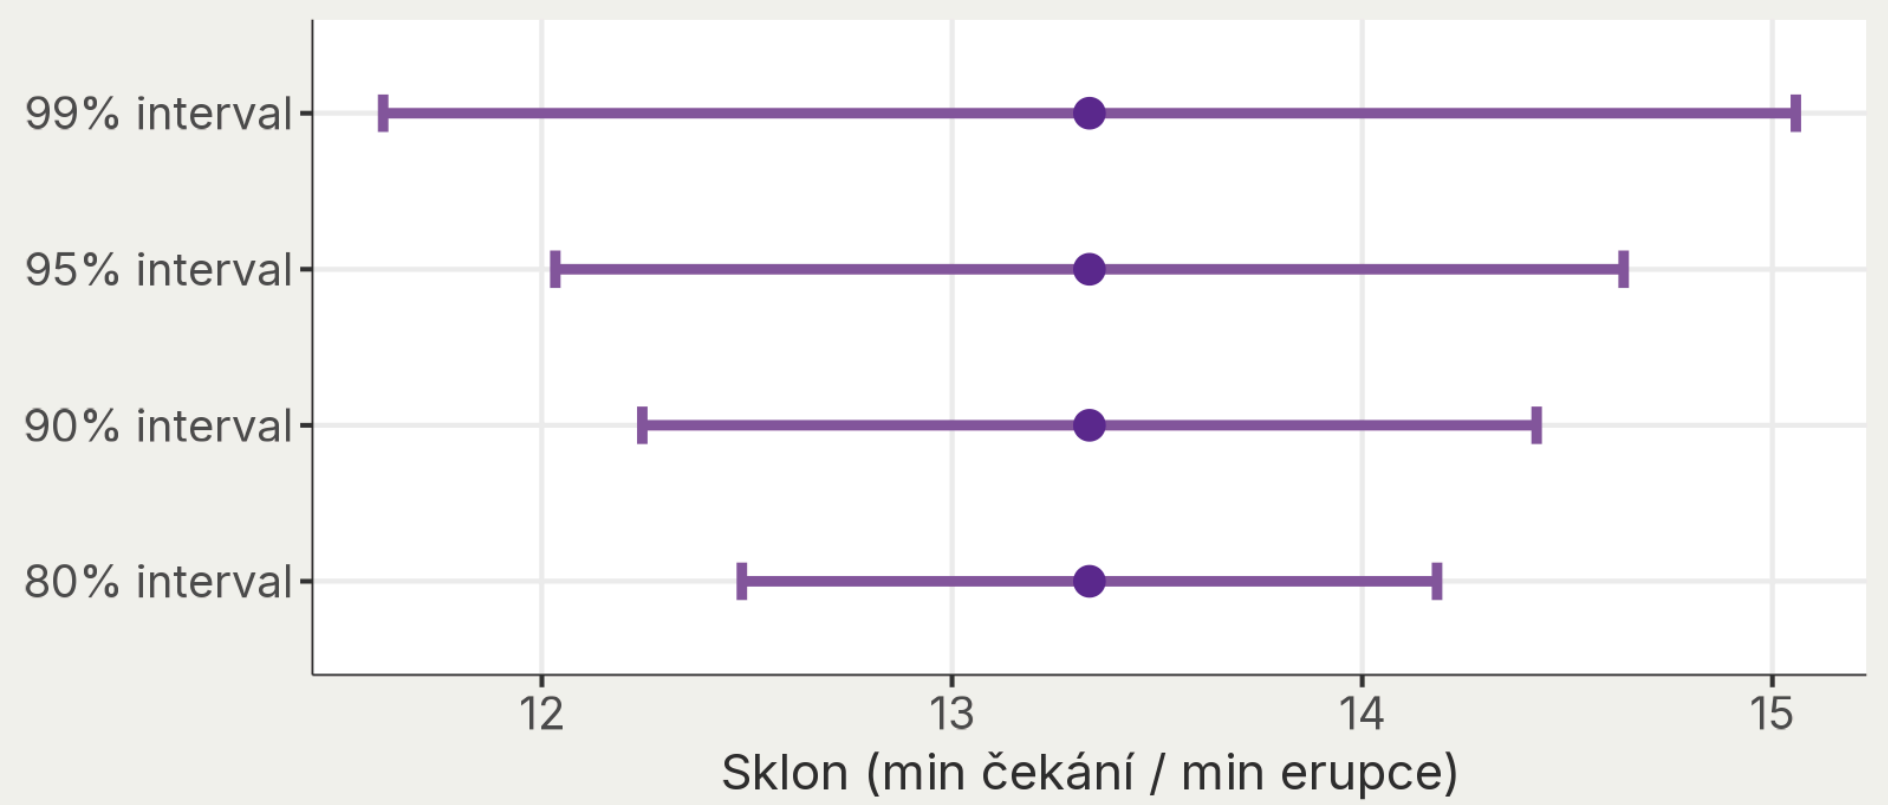
Ze stejných dat spočítáme 80%, 90%, 95% a 99% interval. Jaký bude interval s vyšší hladinou?

A) Užší.

B) Širší.

Ve dvojici seřaďte čtyři intervaly od nejužšího a připravte jedno vysvětlení.

Stejný odhad, různě široké intervaly



Stejný odhad, ale vyšší hladina → širší interval. Co tedy hladina vlastně popisuje?

Užší neznamená automaticky přesnější

Intervaly porovnáváme jako přesnější a méně přesné jen při stejné hladině spolehlivosti.

Snížením hladiny z 95 % na 80 % získáme užší interval, ale z dat jsme nezískali víc informace: data i SE zůstaly stejné.

OTÁZKA

Výzkumník spočítal 95% interval spolehlivosti sklonu. Co znamená „95 %“?

A) 95 % jednotlivých erupcí leží uvnitř intervalu.

B) Skutečný sklon leží po výpočtu uvnitř s pravděpodobností 95 %.

C) Při mnoha opakováních zachytí skutečný sklon přibližně 95 % takto vytvořených intervalů.

Zvolte A, B, nebo C a zdůvodněte svou volbu sousedovi.

Sto pozorovatelů, sto 95% intervalů

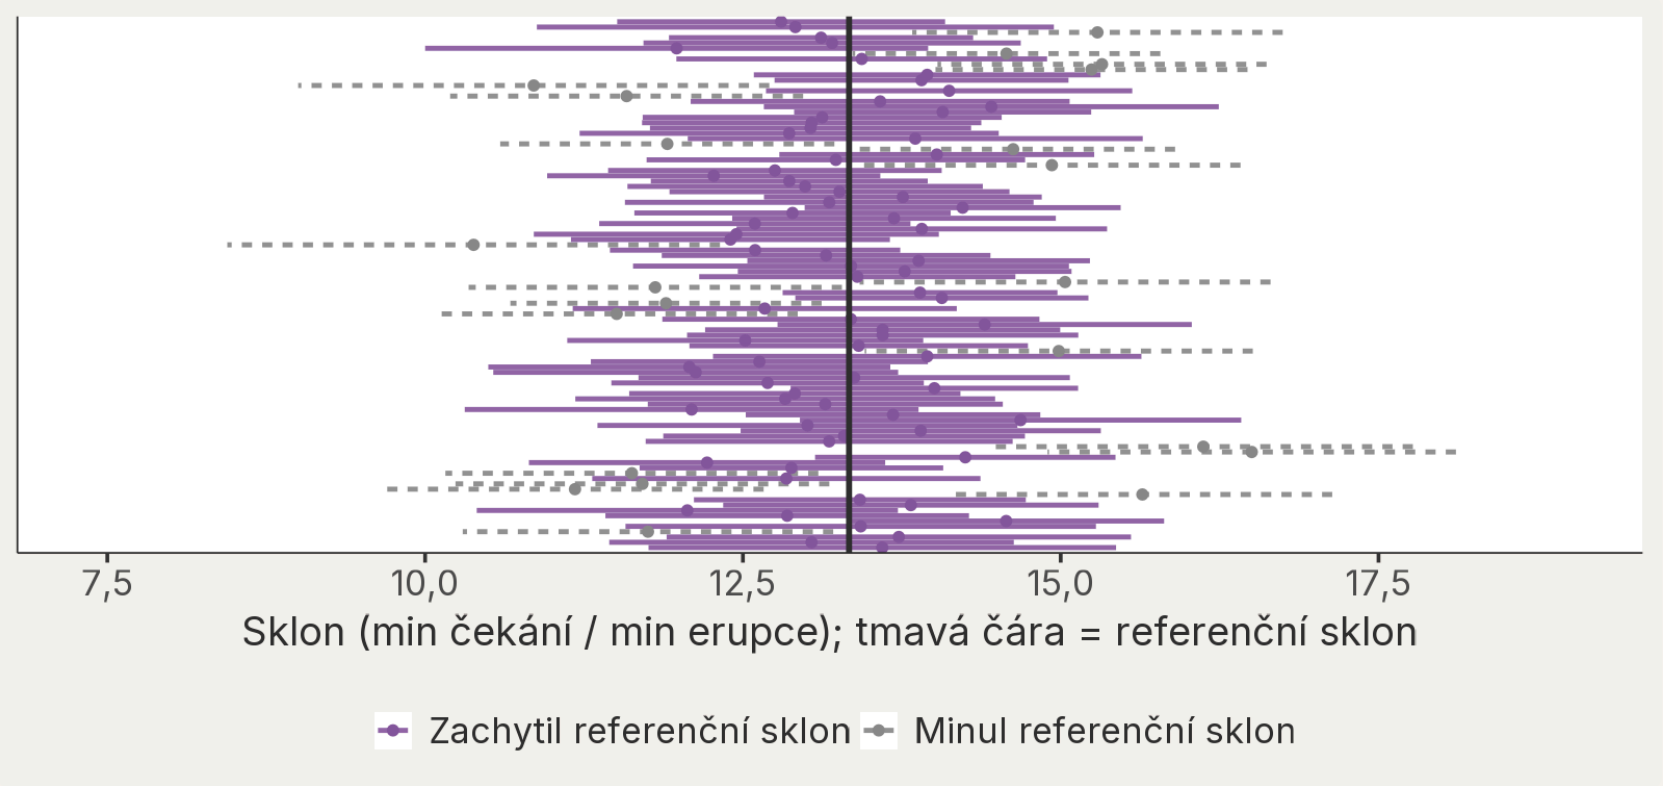
Stejných 100 hlášení, každé se svým vlastním 95% intervalem z `confint()`.



97 ze 100 95% intervalů zachytilo referenční sklon. Ve skutečném výzkumu skutečný sklon neznáme.

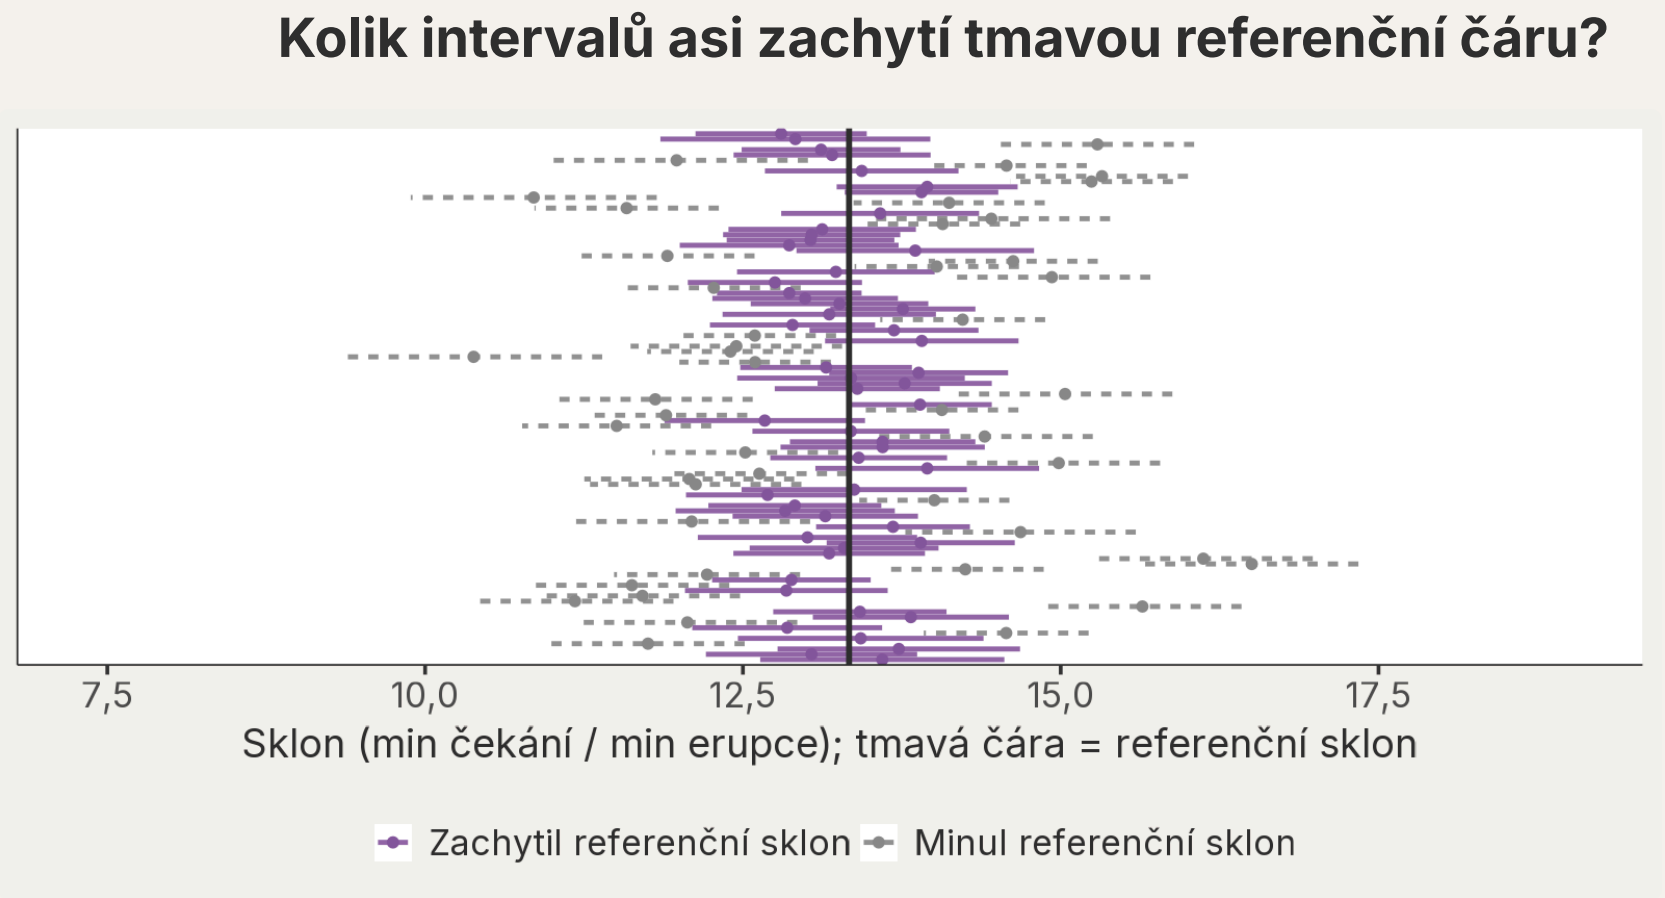
Stejných sto pozorovatelů, 80% intervaly

Co se stane se šířkou intervalů a s počtem šedých intervalů?



78 ze 100 80% intervalů zachytilo referenční sklon. Intervaly jsou užší a častěji míjejí.

Stejných sto pozorovatelů, 50% intervaly



54 ze 100 50% intervalů zachytilo referenční sklon. Hladina popisuje úspěšnost postupu při opakování.

95 % patří k postupu



Ilustrace vytvořená pomocí AI.

ODPOVĚĎ C

Při mnoha srovnatelných opakováních zachytí skutečný sklon přibližně 95 % takto vytvořených intervalů.

NEŘÍKÁME

- 95 % pozorování je uvnitř
- tento interval má 95% šanci obsahovat pravdu
- interval dokazuje určitou hodnotu

OTÁZKA

Nakreslíme přímky všech 100 hlášení GeyserWatch do jednoho grafu. Kde se od sebe budou lišit nejméně?

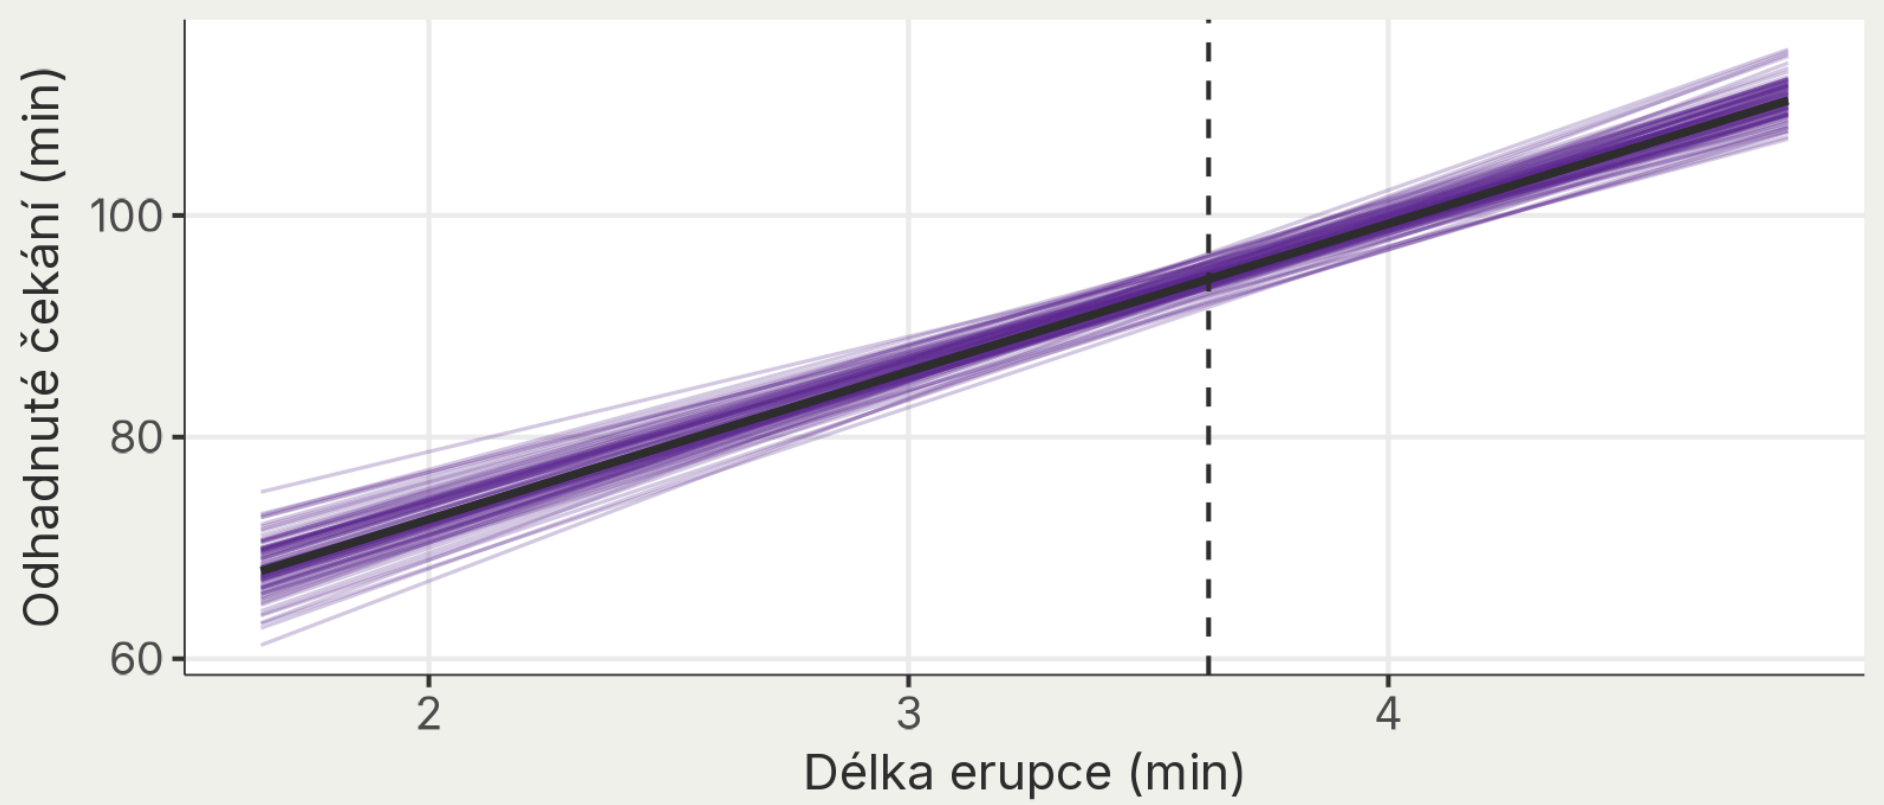
A) U krátkých erupcí.

B) U průměrně dlouhých.

C) U dlouhých erupcí.

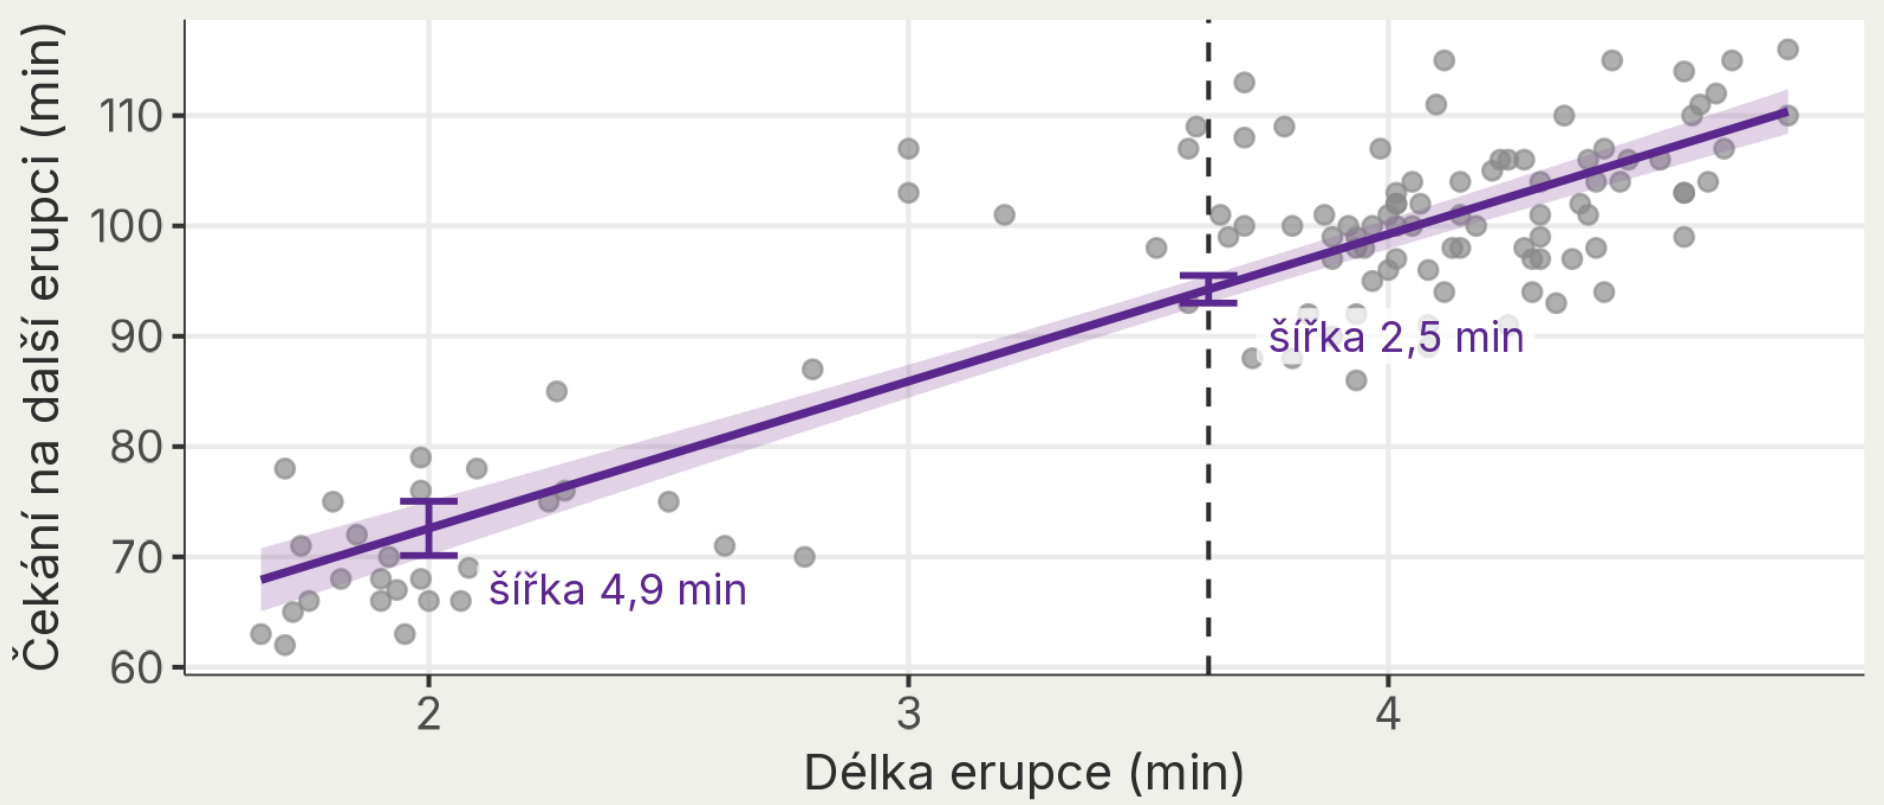
Zvolte A, B, nebo C a zdůvodněte svou volbu sousedovi.

Sto hlášení, sto přímek



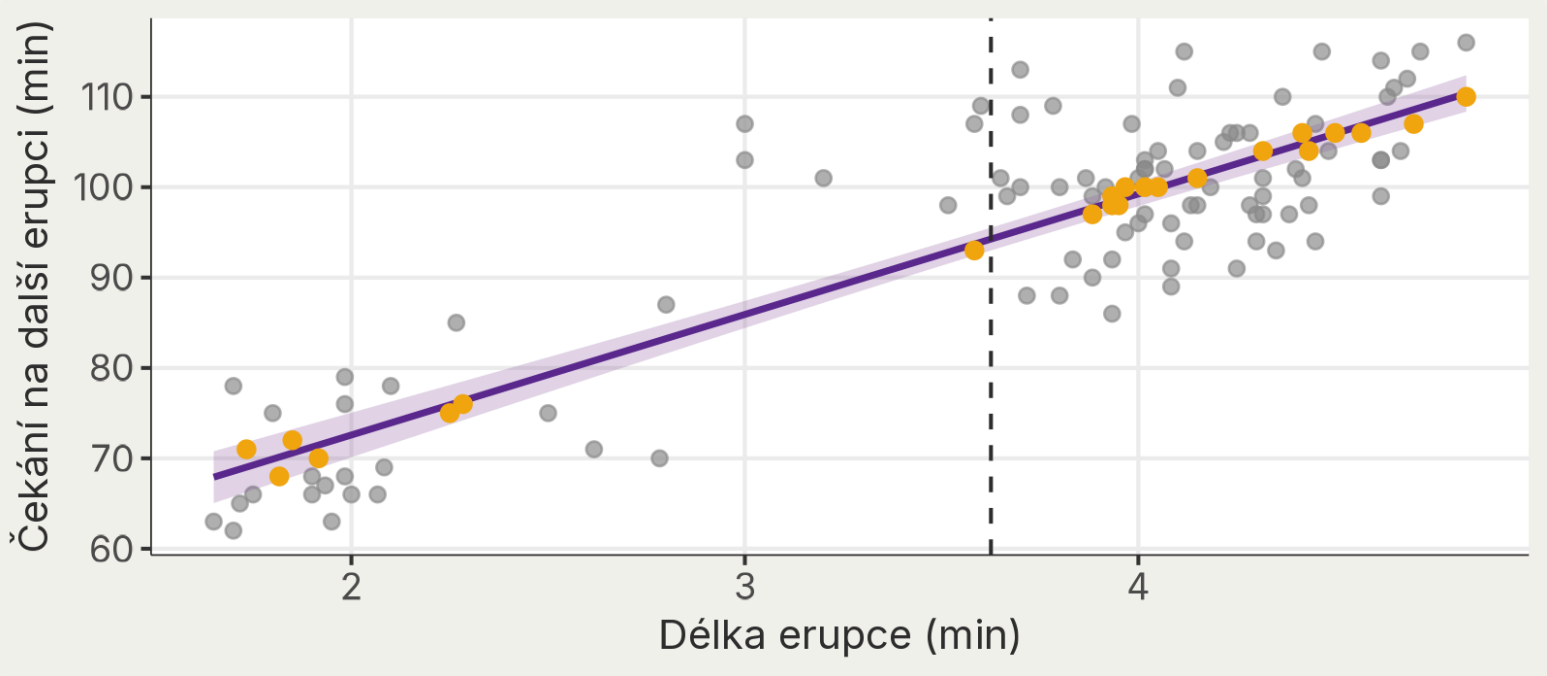
Fialové jsou přímky hlášení, tmavá je přímka ze všech erupcí. Přímky se kříží u průměrné délky erupce (čárkovaně) a k okrajům se rozbíhají.

Pás pro průměrný trend



Pás spolehlivosti: pro každou délku erupce 95% interval pro **průměrné** čekání; hranice vrátí `predict(..., interval = "confidence")`. Nejužší je u průměrné délky erupce (čárkovaně), ne tam, kde je nejvíc bodů.

Kolik erupcí leží uvnitř pásu?



PÁS ≠ KDE LEŽÍ 95 % ERUPCÍ

Uvnitř leží jen **22 ze 117** erupcí. Pás ukazuje, kde může ležet průměrný trend. Rozsah pro jedno nové čekání musí být širší.

Statistická redakce: opravte titulek

DVOJICE — 90 SEKUND

Redakce napsala:

> „Náš interval má 95% šanci obsahovat skutečný sklon.“

Přepište titulek do **jedné přesné věty o postupu**. Nejvýše 15 slov.

Závěr

Co už víme o čekání na další erupci?

O kolik déle čekáme po delší erupci — a jak jistě to víme?

CO UŽ MŮŽEME ŘÍCT

Dvě erupce, jejichž délky se liší o minutu, se v průměru liší čekáním o 13,34 min; s daty a modelem jsou slučitelné sklony od 12,03 do 14,64. Po čtyřminutové erupci je odhadnuté průměrné čekání 99,25 min (95% CI [97,91; 100,60]).

CO ZŮSTÁVÁ OTEVŘENÉ

Jak pomocí dat posoudit konkrétní tvrzení o sklonu — například že délka erupce s čekáním vůbec nesouvisí?

Napište jednu vědeckou větu

DVOJICE — 3 MIN

Věta musí obsahovat:

- vztah mezi délkou erupce a čekáním
- odhad sklonu
- SE a 95% CI
- jednotky
- opatrný jazyk bez tvrzení o příčině

DATA A VÝSLEDEK MODELU

- **117 erupcí** gejzíru Old Faithful, léto 2024
- délka erupce: 1,65–4,83 min
- čekání: 62–116 min
- odhad sklonu: **13,34**
- SE: **0,66**
- 95% CI: **[12,03; 14,64]**
- jednotky: min čekání / min erupce

Vyměňte si větu se sousední dvojicí: jsou v ní proměnné, jednotky a nejistota?

Jedna možná věta

Dvě erupce, jejichž délky se lišily o jednu minutu, se podle lineárního modelu v průměru lišily čekáním na další erupci o **13,34** **± 0,66** minuty (odhad sklonu ± SE; 95% CI [12,03; 14,64] minuty čekání na minutu erupce).

Co ještě omezuje náš závěr?

Dobrovolníci nezaznamenali náhodný výběr všech erupcí a blízké erupce mohou být časově propojené.

Výsledek je opatrný odhad vztahu v zachyceném období — ne neměnný přírodní zákon.



Ilustrace vytvořená pomocí AI.

Shrnutí

- **Jiný soubor pozorování** dává jiný odhad sklonu: to je výběrová variabilita.
- Ve výstupu `summary()` popisuje **`Estimate`** velikost vztahu a **`Std. Error`** jeho přesnost; SE se s více pozorováními zmenšuje.
- **95% interval z `confint()`** ukazuje sklony slučitelné s daty a modelem; 95 % popisuje úspěšnost postupu, ne podíl pozorování ani důkaz.
- **Pás spolehlivosti** ukazuje nejistotu průměrného trendu pro každou délku erupce; je nejužší u průměrné délky a neobsahuje 95 % erupcí.
- Vědecká věta spojuje interpretaci s odhadem, SE, intervalem a jednotkami.

Co potřebujete vidět, než napíšete „po minutě erupce navíc čekáme o 13,34 minuty déle“?

Jaké tři otázky položíte autorovi, který vám ukáže jen tento titulek?

ŘEKNĚTE SOUSEDOVI JEDNOU VĚTOU

Kterou z otázek byste položili jako první, a proč?

Jak posoudit konkrétní tvrzení o sklonu? Následující lekce přidá testování hypotéz.